


Collecte des données & Data visualisation



INTRODUCTION

- Le système opérationnel est axé sur la production, la mémorisation et le traitement des données de l'activité de l'entreprise. On peut distinguer :
 - **Aspect statique** : enregistrement des données, faits, règles et contraintes
 - **Aspect dynamique** : mise à jour (ajout, modification et suppression) des données, faits, règles et contraintes.
- Il est organisé autour de bases de données relationnelles avec les suites logicielles associées (SGBDR tels que Oracle) et le langage SQL.



CONTEXTE : SYSTÈME DÉCISIONNEL (BI)

Besoin



Prise de décisions stratégiques et tactiques

Qui



les décideurs (non informaticiens, non statisticiens)

Comment



Répondre aux demandes d'analyse de données
Dégager des informations qualitatives nouvelles

CONTEXTE : SYSTÈME DÉCISIONNEL (BI)

- Pourquoi le chiffre d'affaires a-t-il baissé ?
 - Quels produits/services ont vu une baisse des ventes ?
 - Y'a-t-il des variations saisonnières ou des tendances du marché ?
 - Les prix ont-ils changé récemment ?
 - Quels segments de clients ont réduit leurs achats ?
- Quels sont les produits ou services les plus rentables ?
 - Quels produits/services ont la meilleure marge bénéficiaire ?
 - Existe-t-il des produits à faible marge qui consomment beaucoup de ressources ?
- Quelles sont les régions ou zones géographiques qui performant le mieux/moins bien ?
 - Y'a-t-il des régions où les ventes diminuent ou stagnent ?
 - Quels facteurs régionaux (concurrence, économie locale) pourraient influencer cela ?

DÉFINITION DE BI

- L'Informatique Décisionnelle (ID), en anglais Business Intelligence (BI), est l'informatique à l'usage des décideurs et des dirigeants des entreprises.
- Les systèmes de ID/BI sont utilisés par les décideurs pour obtenir une connaissance approfondie de l'entreprise et de définir et de soutenir leurs stratégies d'affaires, par exemple :
 - d'acquérir un avantage concurrentiel,
 - d'améliorer la performance de l'entreprise,
 - de répondre plus rapidement aux changements,
 - De fournir des tableaux de bord
 - d'augmenter la rentabilité


EXEMPLE D'UNE BANQUE

- Le système opérationnel
 - va mémoriser toutes les informations sur les clients, leurs différents comptes et les opérations sur ces comptes : débit, crédit, virement, change, déclencher des actions.
- Le système décisionnel
 - conserve sur une période, par exemple mensuelle, le nombre d'opérations, leur montant moyen, la moyenne des soldes sur les différents comptes sur une durée historique d'une ou plusieurs années. Il dispose également d'informations personnelles sur le client.

LES FONCTIONS DE BI

- Fonction de collecte de données
- Fonction d'intégration
- Fonction de distribution
- Fonction présentation

ARCHITECTURE CLASSIQUE DE BI




DONNÉES DE L'ENTREPRISE

- Les données de l'entreprise sont stockées dans des systèmes transactionnels qui enregistrent les données quotidiennes.
- Différentes sources de données :
 - Fichiers Excel, CSV
 - ERP
 - Systèmes de CRM
 - Données du Web
 - Twitter
 - Facebook

INTÉGRATION DES DONNÉES

- Sources diverses et disparates
- Sources sur différentes plateformes
- Qualité de données douteuse et changeante dans le temps
- Structure des systèmes sources changeante dans le temps
- Incohérence entre les différentes sources
- Données dans un format difficilement interprétable ou ambigu



DONNÉES DE L'ENTREPRISE

1ere Approche : Intégration matérialisée

- entrepôt de données
- Les données provenant des sources sont transformées et stockées sur un support spécifique (entrepôt de données).
- L'interrogation s'effectue comme sur une BD classique
- Intégration virtuelle

2ème Approche : médiateur

- Les données restent dans les sources
- Les requêtes sont exprimées sur le schéma global, puis décomposées en sous-requêtes sur les sources
- Les résultats des sources sont combinés pour former le résultat final

INTÉGRATION DES DONNÉES EII - EAI - ETL

EII



SQL
(or Content)

Data Virtualization

Structured
Data Source

Legacy
Data Source

unstructured

EAI



Application

Interpret
Transform
Route



Application



Application

ETL

Target /
Data
Warehouse

load

transform

extract

Data
Source

...

Data
Source

EII – ENTREPRISE INFORMATION INTEGRATION

- **Définition** : Une technologie permettant de **virtualiser les données** en temps réel depuis différentes sources, sans les déplacer. L'EII crée une vue unifiée des données distribuées.
- **Usage** : Accéder à des données en temps réel à partir de multiples systèmes sans les copier dans un entrepôt.
- **Avantages** :
 - Temps réel.
 - Pas besoin de stockage supplémentaire.
 - Vue unifiée des données sans duplication.

EAI – ENTREPRISE APPLICATION INTEGRATION

- **Définition** : Une méthode pour **intégrer les applications d'entreprise** afin qu'elles puissent échanger des données et des processus de manière fluide.
- **Usage** : Connecter des systèmes tels que ERP, CRM, bases de données, etc.
- **Avantages** :
 - Automatisation des processus métier.
 - Réduction des silos d'information.

ETL – EXTRACT TRANSFORM LOAD

« **Extract-Transform-Load** » est connu sous le terme ETL (ou parfois : data pumping). Il s'agit d'une technologie informatique permettant d'effectuer des synchronisations massives d'information d'une banque de données vers une autre.

Elle est basée sur des connecteurs servant à exporter ou importer les données dans les applications, des transformateurs qui manipulent les données (agrégations, filtres, conversions...), et des mises en correspondance (mappages).

Le but est l'intégration de l'entreprise par ses données.

(**E**xtracting - **T**ransforming - **L**oading)

ETL – EXTRACT TRANSFORM LOAD


- **Alimenter un ED**
 - Le principe de l'entreposage des données est de rassembler de multiples données sources qui souvent sont **hétérogènes** en les rendant **homogènes** afin de les analyser.
 - Ce travail d'homogénéisation nécessite des **règles** précises servant de **dictionnaire** (ou de référentiel) et qui seront mémorisées sous forme de **métadonnées** (information sur les données).
 - Ces règles permettent d'assurer des tâches d'administration et de gestion des données entreposées.

ETL – EXTRACT TRANSFORM LOAD

Caractéristiques :

- Permet la consolidation des données à l'aide des trois opérations suivantes :
 - **Extraction** : identifier et extraire les données de sources ayant subi une modification depuis la dernière exécution.
 - **Transformation** : appliquer diverses transformations aux données pour les nettoyer, les intégrer et les agréger.
 - **Chargement** : insérer les données transformées dans l'entrepôt et gérer les changements aux données existantes.
- Traite normalement de grandes quantités de données en lots programmés
- Est surtout utilisé avec les entrepôts de données et les magasins de données.

Tâches et étapes de l'ETL



Le processus d'ETL

L'alimentation d'un ED est un processus qui s'effectue en plusieurs étapes :


Sélection des données sources

Extraction des données

Transformation

Chargement

Le processus d'ETL



*Conversion de type, correction, filtre, agrégation, formatage

Sélection des données sources

- Quelles sont les données de production qu'il faut sélectionner pour alimenter l'ED ?
- Toutes les données sources ne sont forcément pas utiles.
 - Doit-on prendre l'adresse complète ou séparer le code postal ?
- La synthèse de ces données sources a pour but de les enrichir.
- La dénormalisation des données crée des liens entre les données et permet des accès différents

Sélection des données sources

Il existe plusieurs niveaux de données :

- Les données sont parfois assemblées avant d'être injectées dans l'ED permettant une vision intégrée et transversale de l'entreprise.
- Cette forme de données constitue **le niveau le plus fin** au niveau de l'ED : ceux sont **les données de détail**. Elles peuvent être agrégées et constituent ainsi un autre niveau de détail.
- Elles seront par la suite **structurées** dans des espaces d'analyse
- Elles seront finalement à **un niveau de présentation**, où elles peuvent avoir plusieurs formes (tableaux, graphiques, tableaux de bord, règles de connaissances...).

Extraction des données

- L'extraction peut se faire à travers un outil d'alimentation qui doit travailler de façon native avec les SGBD qui gèrent les données sources.
- Ou alors créer des programmes extracteurs. L'inconvénient de cette approche est le risque de faire des extractions erronées, incomplètes.
- Il faut gérer les anomalies en les traitant et en gardant une trace
- **L'extraction** doit se faire conformément aux règles précises du **référentiel**.
- Elle ne doit pas non plus **perturber** les activités de production.
- Il faut faire attention aux données **cycliques**. Celles qu'on doit calculer à chaque période, pour pouvoir les prendre en considération.
- L'extraction peut se faire en **interne** selon l'horloge interne ou par un **planificateur** ou par la détection d'une donnée cible (de l'ED) ; ou en externe par des **planificateurs externes**.

Transformation des données

C'est une suite d'opérations qui a pour but de rendre les données cibles homogènes et puissent être traitées de façon cohérente.

Données sources	Données cibles
Appli 1 : male, femelle	M, F
Appli 2 : 0, 1	M, F
Appli 3 : masculin, féminin	M, F

Données sources	Données cibles
Appli 1 : 10\$	9 €
Appli 2 : 16 000 €	16 000 €
Appli 3 : 200,000 €	1 940 000 €

Transformation des données

- Les données doivent alors être filtrées afin d'éliminer les données aberrantes:
 - données sans valeurs avec des valeurs manquantes.
 - Souvent dans les bases de production, certaines données sont sémantiquement fausses.
 - Pour avoir une alimentation de qualité, il faut avoir une bonne connaissance des données à entreposer et des règles qui les régissent.
 - Savoir corriger les données pour les doter d'un vrai sens sémantique.
 - On peut dédoubler des données pour gagner au niveau de la cohérence.
- L'ensemble des données sources, après nettoyage ou transformation d'après des règles précises ou par application de programmes, seront restructurées et converties dans un format cible.

Transformation des données

- Matrice de la transformation

[illegible]

Alimenter ED

- Le dictionnaire (ou référentiel) de données est constitué de l'ensemble des métadonnées.
- Il renferme des informations sur toutes les données de l'ED.
- Il renferme également des informations sur chaque étape
 - Le rôle des métadonnées est de permettre :
 - La définition des données
 - La fabrication des données
 - Le stockage des données
 - L'accès aux données
 - La présentation des données.

Alimenter ED

il existe trois catégories d'outils ETL :

- 1.Engine-based** : les transformations sont exécutées sur un serveur ETL, disposant en général d'un référentiel. Ce genre de d'outil dispose d'un moteur de transformation ;
- 2.Database-embedded** : les transformations sont intégrées dans la BD ;
- 3.Code-generators** : les transformations sont conçues et un code est généré. Ce code est déployable indépendamment de la base de données.

EXERCICE 1

On veut construire un entrepôt de données afin de stocker les informations sur les consultations d'un pays. On veut notamment connaître le nombre de consultations, par rapport à différents critères (personnes, médecins, spécialités, etc. Ces informations sont stockées dans les relations suivantes :


PERSONNE (id, nom, tel, adresse, sexe)

MEDECIN (id, tel, adresse, spécialité)

CONSULTATION (id_med, id_pers, date, prix)

1. Proposer un schéma relationnel qui tienne compte de la date, du jour de la semaine, du mois, du trimestre et de l'année.


Correction



CARACTÉRISTIQUES D'UN ENTREPÔT DE DONNÉES

Données orientées sujet


- Regroupe les informations des différents métiers
- Ne tiens pas compte de l'organisation fonctionnelle des données



CARACTÉRISTIQUES D'UN ENTREPÔT DE DONNÉES

Données intégrées

- Normalisation des données
- Définition d'un référentiel unique



CARACTÉRISTIQUES D'UN ENTREPÔT DE DONNÉES

Données historiées / datées

- Les données persistent dans le temps
- Mise en place d'un référentiel temps

Base de
production

Image de la base en Mai 2005

Répertoire

Nom	Ville
Dupont	Paris
Durand	Lyon

Image de la base en Juillet 2006

Répertoire

Nom	Ville
Dupont	Marseille
Durand	Lyon

Entrepôt
de
données

Calendrier

Code	Année	Mois
1	2005	Mai
2	2006	Juillet

Répertoire

Code	Année	Mois
1	Dupont	Paris
1	Durand	Lyon
2	Dupont	Marseille

MODÉLISATION DIMENSIONNELLE


Niveau conceptuel

- Description de la base dimensionnelle indépendamment des choix d'implantation
- Les concepts :
 - Dimensions et hiérarchies
 - Faits et mesures

MODÉLISATION DIMENSIONNELLE

Dimension

- Axes d'analyse avec lesquels on veut faire l'analyse : Géographique, temporel, produits, ...
- Chaque dimension comporte un ou plusieurs attributs/membres
- Une dimension est tout ce qu'on utilisera pour faire nos analyses.



HIÉRARCHIE

- Les attributs/membres d'une dimension sont organisés suivant des hiérarchies
- Chaque membre appartient à un niveau hiérarchique (ou niveau de granularité) particulier

Dimension temporelle : jour, mois, année

Dimension géographique : magasin, ville, région, pays

Dimension produit : produit, catégorie, marque, etc.

Attributs définissant les niveaux de granularité sont appelés paramètres

Attributs informationnels liés à un paramètre sont dits attributs faibles

GRANULARITÉ

- Les attributs/membres d'une dimension sont organisés suivant des hiérarchies
- Chaque membre appartient à un niveau hiérarchique (ou niveau de granularité) particulier

Dimension temporelle : jour, mois, année

Dimension géographique : magasin, ville, région, pays

Dimension produit : produit, catégorie, marque, etc.

Attributs définissant les niveaux de granularité sont appelés paramètres

Attributs informationnels liés à un paramètre sont dits attributs faibles

FAIT

- Sujet analysé
- Un ensemble d'attributs appelés mesures (informations opérationnelles)
- Les ventes (chiffre d'affaires, quantités et montants commandés, volumes des ventes)
- Les stocks (nombre d'exemplaires d'un produit en stock, ...)
- les ressources humaines (nombre de demandes de congés, nombre de démissions)
- Un fait représente la valeur d'une mesure, calculée ou mesurée, selon un membre de chacune des dimensions

FAIT

Exemple :

250 000 euros est un fait qui exprime la valeur de la mesure **Coût** des travaux pour le membre 2002 du niveau **Année** de la dimension **Temps** et le membre Versailles du niveau Ville de la dimension **Découpage administratif**.

La table de fait contient les valeurs des mesures et les clés vers les tables de dimensions

Clés étrangères
vers les
dimensions

Faits

Table de faits des ventes
Clé date (CE)
Clé produit (CE)
Clé magasin (CE)
Quantité vendue
Coût
Montant des ventes

MESURE

- Élément de donnée sur lequel portent les analyses, en fonction des différentes dimensions.
- Ces valeurs sont le résultat d'opérations d'agrégation sur les données


Exemple :

- Coût des travaux
- Nombre d'accidents
- Ventes

CLÉ

- Tables de dimension
 - Clé primaire
- Tables de fait
 - Clé composée
 - Clés étrangères des tables de dimension


MODÈLE EN ÉTOILE



MODÈLE EN ÉTOILE

- Une table de fait centrale et des dimensions
- Les dimensions n'ont pas de liaison entre elles
- Avantages :
 - Facilité de navigation
 - Nombre de jointures limité
- Inconvénients :
 - Redondance dans les dimensions

MODÈLE EN FLACON



MODÈLE EN ÉTOILE


- Modèle en étoile + normalisation des dimensions
- Une table de fait et des dimensions en sous-hiérarchies
- Un seul niveau hiérarchique par table de dimension
- La table de dimension de niveau hiérarchique le plus bas est reliée à la table de fait (elle a la granularité la plus fine)
- Avantages :
 - Normalisation des dimensions
 - Economie d'espace disque (réduction du volume)
- Inconvénients :
 - Modèle plus complexe (nombreuses jointures)
 - Navigation difficile

EXEMPLE DE L'AGENCE DE VOYAGE 1-VOYAGES AÉRIENS

Quel est le chiffre d'affaires (CA) par client, par date de voyage (et par mois, trimestre et année), par compagnie aérienne, par ville de destination?

Les tableaux de bord doivent pouvoir présenter les totaux et sous totaux de CA: tous clients confondus, et/ou toutes dates, et/ou toutes compagnies, et/ou toutes destinations.


EXEMPLE DE L'AGENCE DE VOYAGE 1-VOYAGES AÉRIENS



EXEMPLE DE L'AGENCE DE VOYAGE 2-HÔTEL

Dans le cas de l'hôtellerie, on veut des tableaux de bord par client, hôtel, ville, date de début de séjour, faisant apparaître le nombre de nuitées et le prix total payé.

EXEMPLE DE L'AGENCE DE VOYAGE 2-HÔTEL




EXEMPLE DE L'AGENCE DE VOYAGE 2-HÔTEL

Dans le cas de l'hôtellerie, on veut des tableaux de bord par client, hôtel, ville, date de début de séjour, faisant apparaître le nombre de nuitées et le prix total payé.

EXEMPLE DE L'AGENCE DE VOYAGE 3-LOCATION DE VOITURE

Dans le cas de la location de voiture, on souhaite éditer le CA, le nombre de jours de location, et le kilométrage pour chaque: client, date de réservation, ville, loueur, et catégorie de véhicule, ainsi que toutes les sommes de la même manière que pour les déplacements.


EXEMPLE DE L'AGENCE DE VOYAGE 3-LOCATION DE VOITURE



EXEMPLE DE L'AGENCE DE VOYAGE REGROUPEMENT

- On veut maintenant regrouper ces trois ED en un seul, afin de répondre aux questions supplémentaires suivantes: Quel est le CA total induit par un déplacement en avion? Quelle est la durée du séjour? Quel est le CA en location de voiture? En hôtellerie?
- On veut pouvoir éditer les détails de CA par période de temps et par client, ville, compagnie aérienne, loueur et hôtelier, et faire tous les regroupements utiles.
- Figurer le modèle dimensionnel d'un tel ED, en montrant en particulier comment l'on peut retrouver location de voiture et/ou hôtellerie, si elles existent, à partir d'un déplacement en avion. Un voyage en avion n'implique pas forcément location de voiture et/ou hôtellerie, et inversement.

EXEMPLE DE L'AGENCE DE VOYAGE REGROUPEMENT



UML

- UML est un langage de modélisation et non une méthode.
- UML c'est langage graphique qui permet de représenter et de communiquer les différents aspects d'un système d'information.
- UML couvre toutes les étapes du développement d'un système d'information
- UML est **l'Unified Modeling Language** est un formalisme graphique
- UML permet de décrire et concevoir des systèmes logiciels

UML

- UML sert à :
 - Décomposer le processus de développement,
 - Mettre en relation les experts métiers et les analystes,
 - Coordonner les équipes d'analyse et de conception,
 - Migrer facilement vers une architecture
 - Indépendant des langages de programmation
- Langage = syntaxe + sémantique :
 - syntaxe : notations graphiques consistant
 - essentiellement en des représentations
 - conceptuelles d'un système
 - sémantique : sens précis pour chaque notation

DIAGRAMME D'UML

Les diagrammes




DIAGRAMME D'UML

Les vues




DIAGRAMME D'UML




DIAGRAMME D'UML

- **Diagramme de cas d'utilisation** : décrit les fonctions du système selon le point de vue des futurs utilisateurs
- **Diagramme de séquence** : représentation des interactions temporelles entre objets dans la réalisation d'une interface Homme Système
- **Diagramme de classes** : structure des données du système définies comme un ensemble de relations entre classes
- **Diagramme d'objets** : illustration des objets et de leurs relations
- **Diagramme de collaboration** : représentation des interactions entre objets
- **Diagramme d'états-transitions** : représentation du comportement des objets d'une classe en termes d'états et de transitions d'états
- **Diagramme d'activités** : structure d'une opération en actions

DIAGRAMME D'UML

- **Diagramme de séquence** : représentation des interactions temporelles entre objets dans la réalisation d'une opération
- **Diagramme de déploiement** : description du déploiement des composants sur les dispositifs matériels
- **Diagrammes de composants** : architecture des composants physiques d'une application

DIAGRAMME DE CLASSES





DIAGRAMME DE CAS D'UTILISATION




EXERCICE 1

Chronodrive est un site commercial qui permet de faire des courses en ligne et de venir au magasin les récupérer au drive. Sur l'écran de la borne automatique de magasin, il y a deux options : « commande sur place » ou « retrait de marchandises ». Pour retirer les marchandises, il faut obligatoirement saisir le code client et procéder au paiement si ce n'est pas encore fait sur le site.

Modéliser les fonctionnalités proposées par la borne automatique via un diagramme de cas d'utilisation.

EXERCICE 1



EXERCICE 2

Dans un établissement scolaire, on désire gérer la réservation des salles de cours ainsi que du matériel pédagogique (ordinateur portable ou/et Vidéo projecteur).

Seuls les enseignants sont habilités à effectuer des réservations (sous réserve de disponibilité de la salle ou du matériel).


Le planning des salles peut quant à lui être consulté par tout le monde (enseignants et étudiants).

Cependant, le récapitulatif horaire par enseignant (calculé à partir du planning des salles) ne peut être consulté que par les enseignants.

Enfin, il existe pour chaque formation un enseignant responsable qui seul peut éditer le récapitulatif horaire pour l'ensemble de la formation.

Modéliser cette situation par un diagramme de cas d'utilisation

EXERCICE 2



EXERCICE 3

Nous nous intéressons aux fonctionnalités suivantes de la gestion de la bibliothèque :

- **Classification des documents effectuée par la bibliothécaire** : quand la bibliothécaire reçoit un document, elle doit inscrire le document dans la base de données et lui attribuer un code de rangement dans la bibliothèque.
- **Consultation des index des documents** : chaque adhérent est capable de consulter la liste d'index liés à un document donné via des terminaux disponibles dans la bibliothèque.
- **Emprunt d'un livre effectué par l'adhérent à l'aide de la bibliothécaire** : l'adhérent peut se présenter au comptoir du prêt avec les documents à emprunter et sa carte d'inscription. Le système vérifie si le nombre de documents déjà emprunté ne dépasse pas un seuil donné et qu'aucune date de retour n'a été dépassée. L'emprunt est inscrit et la date de retour est fixée.
- **Location d'un livre** : pour certains livres, le prêt gratuit n'est pas possible et dans ce cas, il faut louer. La location se passe exactement comme le prêt avec la seule différence qui est la suivante:

l'adhérent doit payer le montant de la location.

- **Retourner des documents** : l'adhérent se présente au comptoir avec les documents à retourner et sa carte. La bibliothécaire enregistre le retour des documents dans le système.
- Le système est accessible que par une phase d'authentification avec un identifiant et un mot de passe.


Déterminer les cas d'utilisation et les acteurs primaires et secondaires associés.

EXERCICE 3

Cas d'utilisation	Acteur principal	Acteur secondaire
1) Classifier document	Bibliothécaire	
2) Consulter document	Adhérent	
3) Emprunter livre	Adhérent	Bibliothécaire
4) Louer livre	Adhérent	Bibliothécaire
5) Retourner document	Adhérent	Bibliothécaire
6) S'authentifier	Adhérent, Bibliothécaire	

OBJET

- Un objet est une structure informatique définie par un état et un comportement
- Objet = état + comportement + Identité
- L'état regroupe les valeurs instantanées de tous les attributs de l'objet.
- Le comportement regroupe toutes les compétences et décrit les actions et les réactions de l'objet. Autrement dit le comportement est défini par les opérations que l'objet peut effectuer.
- L'état d'un objet peut changer dans le temps.



CLASSES

- La classe décrit le domaine de définition d'un ensemble d'objets.
- Une classe est définie par : Les attributs, Les méthodes.
- Les attributs permettent de décrire l'état des objets de cette classe.
- Chaque attribut est défini par : Son nom, Son type, Éventuellement sa valeur initiale.
- Les méthodes permettent de décrire le comportement des objets de cette classe.
- Une méthode représente une procédure ou une fonction qui permet

Nom de la classe
Nom_Attribut : type = valeur initiale
Nom_Operation (liste_arguments) : type

Personne
nom : String
adresse : String
dateNaissance:Date
age() : int
changerAdresse(String a) : void

Point
x : int
y : int
toString():String
distance(Point p) : double

Encapsulation

- Les membres d'une classe peuvent être protégés en utilisant quatre **niveaux de protection** :
- **Public (+)** : Accès à partir de toute entité interne ou externe à la classe
- **Protégé (#)** : Accès à partir de la classe ou des classes dérivées
- **Privé (-)** : accès à partir des opérations de la classe


Personne
- nom : String
adresse : String
dateNaissance : Date
+ age() : int
+ changerAdresse(String a) : void

c1:Compte
code=1
solde=6000
verser(float mt)
retirer(float mt)
toString()

Exercice 1

- Un répertoire contient des fichiers
- Une pièce contient des murs
- Les modems et claviers sont des périphériques d'entrée / sortie
- Une transaction boursière est un achat ou une vente
- Un compte bancaire peut appartenir à une personne physique ou morale


Exercice 1



Exercice 2

- On souhaite gérer les réservations de vols effectués dans une agence. D'après les interviews réalisées avec les membres de l'agence, on sait que :
 - Les compagnies aériennes proposent différents vols
 - Un vol est ouvert à la réservation et refermé sur ordre de la compagnie
 - Un client peut réserver un ou plusieurs vols, pour des passagers différents
 - Une réservation concerne un seul vol et un seul passager
 - Une réservation peut être confirmée ou annulée
 - Un vol a un aéroport de départ et un aéroport d'arrivée
 - Un vol a un jour et une heure de départ, et un jour et une heure d'arrivée
 - Un vol peut comporter des escales dans un ou plusieurs aéroport(s)
 - Une escale à une heure de départ et une heure d'arrivée
 - Chaque aéroport dessert une ou plusieurs villes

Exercice 2



TYPE D'ETL

1. ETL propriétaire



2. ETL Open Source



ETL PROPRIETAIRE



Mise en œuvre rapide



Interface généralement complète




Achat des licences et formations



Coût élevé dès le début du projet

COÛT ETL PROPRIETAIRE



ETL OPEN SOURCE



Pas de licence



**Coût de la formation et souscription
hotline technique**




Coût constant tout au long du projet



Partage des travaux

COÛT ETL PROPRIETAIRE



INTEGRATION DES DONNEES AVEC TALEND

Talend Open Studio

« Talend Open Studio 1 » est un ensemble de produits open source pour le développement, test, déploiement et administration des projets d'intégration de données et d'applications.

Talend fournit une plateforme unifiée qui rend la gestion et l'intégration des données et applications plus facile, en fournissant un environnement unifié pour la gestion de tout leur cycle de vie.

INTEGRATION DES DONNEES AVEC TALEND

Prérequis



Le langage SQL : Le Guide Complet

 Noureddine DRISSI

Note : ★★★★★ Vues : 491.287

[Voir](#)



Java (1/2): Réussir la certification OCA examen 1Z0-803

 Fabien BRISSONNEAU

Note : ★★★★★ Vues : 225.740

[Voir](#)

INTEGRATION DES DONNEES AVEC TALEND

Certification

Talend DI v6 Certified Developer


60 questions

1 heure 30

Résultat minimum : 80%




INTEGRATION DES DONNEES AVEC TALEND



1	Panneau représentant la structure de votre projet.
2	Panneau affichant l'architecture des Jobs et le code
3	Onglets contenant les propriétés des composants, la console d'exécution, les problèmes...
4	Palette des différents composants disponibles.

INTEGRATION DES DONNEES AVEC TALEND



1	Panneau représentant la structure de votre projet.
2	Panneau affichant l'architecture des Jobs et le code
3	Onglets contenant les propriétés des composants, la console d'exécution, les problèmes...
4	Palette des différents composants disponibles.

INTEGRATION DES DONNEES AVEC TALEND

Il existe plusieurs solutions offertes par Talend :

- Big Data : Environnement qui facilite la gestion des données volumineuses.
- Data Intégration : Ensemble d'outils pour l'intégration de données pour accéder, transformer et intégrer les données à partir d'un système en temps réel pour remplir les besoins d'intégration des données.
- Data Quality : Permet d'assurer le profiling et monitoring des données pour identifier des anomalies et assurer la qualité des données.
- ESB : Permet la création, la connexion, la médiation et la gestion des services et leurs interactions.

Python pour l'analyse des données

- L'apprentissage d'un langage informatique comme Python va nécessiter d'écrire des lignes de codes à l'aide d'un éditeur de texte (exemple : anaconda, EduPython, , IDLE python)
- Premier contact avec Python est un langage interprété, c'est-à-dire que chaque ligne de code est lue puis interprétée afin d'être exécutée par l'ordinateur.
- Comme tout langage informatique, on peut enregistrer ces instructions dans un fichier, que l'on appelle communément un script (ou programme) Python

Python pour l'analyse des données - Pandas

- Pandas est une librairie ou bibliothèque python qui permet de manipuler facilement des données à analyser :
- Manipuler des tableaux de données avec des étiquettes de variables (colonnes) et d'individus (lignes).
- Ces tableaux sont appelés Data Frames. On peut facilement lire et écrire ces data frames à partir ou vers un fichier tabulé.
- On peut facilement tracer des graphes à partir de ces data Frames grâce à matplotlib.
- Le module pandas a été conçu pour la manipulation et l'analyse de données. Il est particulièrement puissant pour manipuler des données structurées sous forme de tableau.
- Pour charger pandas dans la mémoire de Python, on utilise la commande import habituelle : `import pandas as pd`

ETL

```
def load(data_frame, target_table):  
    # Some custom-built Python logic to load data to SQL  
    data_frame.to_sql(name=target_table, con=POSTGRES_CONNECTION)  
    print(f"Loading data to the {target_table} table")  
  
# Now, run the data pipeline  
extracted_data = extract(file_name="raw_data.csv")  
transformed_data = transform(data_frame=extracted_data)  
load(data_frame=transformed_data, target_table="cleaned_data")
```

ELT – PYTHON

```
...  
def transform(source_table, target_table):  
    data_warehouse.run_sql("""  
        CREATE TABLE {target_table} AS  
        SELECT  
            <field-name>, <field-name>, ...  
        FROM {source_table};  
    """)  
  
# Similar to ETL pipelines, call the extract, load, and transform functions  
extracted_data = extract(file_name="raw_data.csv")  
load(data_frame=extracted_data, table_name="raw_data")  
transform(source_table="raw_data", target_table="cleaned_data")
```

Exercice

Exercice 1

Ecrire un Pandas programme pour lire un fichier Excel existant (exemple :

c:/export_etab_20250202.xlsx)

Lancer le logiciel « Anaconda navigator / Spider », écrire le code source , enregistrer le fichier sous le nom (lecturefichier.py)

```
import pandas
```

```
df = pandas.read_excel (C:/export_etab_20250202.xlsx)
```

```
print(df.head)
```

Exercice

Exercice 1

Instruction	Rôle
Import pandas	Importer la bibliothèque appelée 'pandas' qui représente les procédures et les fonctions prédéfinies de python
df = pandas.read_excel(le chemin d'accès du fichier)	Df c'est le nom du Data frame créée: (= tableau de données) Read : c'est pour lire le fichier Excel indiqué entre les parenthèses
Print (df.head)	Ecrire ou afficher toutes les lignes du tableau sur l'écran de l'ordinateur

header = 0 : la ligne numéro 0 correspond aux noms des champs du tableau

Exercice

Exercice 2

Ecrire un Pandas programme pour lire les colonnes (1, 2 et 4) du fichier

Lancer le logiciel « Anaconda navigator / Spider », écrire le code source , enregistrer le fichier sous le nom (lirecolonne.py)

```
import pandas  
colonnes = [1, 2, 3, 4, 5]  
df = pandas.read_excel ('C:/export_etab_20250202.xlsx', usecols=colonnes)  
print(df.head)
```

Exercice

Exercice 2

Instruction	Rôle
Import pandas	Importer la bibliothèque appelée 'pandas' qui représente les procédures et les fonctions prédéfinies de python
Cols = [1, 2, 3, 4, 5]	On définit les numéros des colonnes à afficher
df = pandas.read_excel (le chemin d'accès du fichier), usecols=cols	Df c'est Data frame : (= tableau de données) Read : c'est pour lire le fichier Excel indiqué entre les parenthèses et utiliser les colonnes définies dans cols
Print(df.head)	Ecrire ou afficher toutes les colonnes du fichier sur l'écran de l'ordinateur

Exercice

Exercice 3

Ecrire un Pandas programme pour déterminer et afficher (la somme, la moyenne, le minimum et le maximum) de la colonne «Nombre d'étudiants» du fichier

Exercice

Exercice 4

Ecrire un Pandas programme pour insérer ou ajouter une colonne vide (nan) à la position zéro (0) (début du fichier) nommée Région.

Remplir ce fichier avec les données

Exercice

Exercice 5

NOM	PRENOM	QUALIFICATION	VILLE	SALAIRE	SEXE	AGE 2020
Bernard	Loïc	Agent	Grenoble	1800	M	50
Thomas	Farel	Maitrise	SMH	2000,56	M	38
Derbal	Yanis	Cadre	Grenoble	2300	M	56
Boucher	Emilie	Agent	Claix	1700,54	F	31
Azzaro	Lina	Agent	Gières	1650,30	F	21
Loizeau	Hervé	Agent	Eybens	1738,21	M	25
Bouchard	Hamid	Agent	Grenoble	1554,83	M	23
Wang	Lei	Agent	Eybens	1769,10	M	35
Abou	Louna	Cadre	Gières	2100,57	F	42
Joel	Catherine	Maitrise	SMH	2032	F	46
Jogoti	Albert	Maitrise	SMH	1972,28	M	48
Bergerot	Philippe	Agent	Claix	1723,47	M	39
Castet	Laetitia	Cadre	Echirrolles	2389,67	F	60

Exercice

Exercice 5

1. Lire et afficher le tableau
2. Afficher les noms de colonnes du tableau
3. Afficher le type de chaque colonne
4. Afficher les premières lignes du tableau de la colonne NOM
5. Afficher les dernières lignes du tableau de la colonne NOM
6. Afficher l'âge maximale
7. Afficher la première valeur de la colonne « AGE 2020 »
8. Afficher les 3 premières valeurs de la colonne « AGE 2020 »
9. Afficher les valeurs de la colonne « AGE 2020 » triées ou classées d'une manière croissante (du petit au grand)
10. Afficher le nombre de personnes pour chaque ville

Exercise

Exercise 5

1/

```
import pandas  
df = pandas.read_excel('D:/application.xlsx')  
print(df.head)
```

2/

```
import pandas  
df = pandas.read_excel('D:/application.xlsx')  
print(df.columns)
```

3/

```
import pandas  
df = pandas.read_excel('D:/application.xlsx')  
print(df.dtypes)
```

Exercise

Exercise 5

4/

```
import pandas  
df = pandas.read_excel('D:/application.xlsx')  
print(df['NOM'].head())
```

5/

```
import pandas  
df = pandas.read_excel('D:/application.xlsx')  
print(df['NOM'].tail())
```

6/

```
import pandas  
df = pandas.read_excel('D:/application.xlsx')  
print(df['AGE 2020'].max())
```

Exercise

Exercise 5

7/

```
import pandas  
  
df = pandas.read_excel('D:/application.xlsx')  
  
print(df['AGE 2020'][0])
```

8/

```
import pandas  
  
df = pandas.read_excel('D:/application.xlsx')  
  
print(df['AGE 2020'][0:3])  
  
ou bien :  
  
df = pandas.read_excel('D:/application.xlsx')  
  
print(df. AGE 2020 [0:3])
```

9/

```
import pandas  
  
df = pandas.read_excel('D:/application.xlsx')  
  
print(df['AGE 2020'].sort_values())
```

Exercise

Exercise 5

10/

```
import pandas  
  
df = pandas.read_excel('D:/application.xlsx')  
  
print(df['VILLE'].value_counts())
```

Exercice

Exercice 6

Analyse des données du fichier **Stats des accidents.csv**

- Donner les informations du fichier
- Afficher le nombre de valeurs manquantes pour chaque colonne
- Donner des statistiques descriptives des colonnes numériques
- Donner le nombre des accidents par année
- Donner le nombre des accidents par jour
- Nombre d'accident dans la zone rurale et zone urbaine
- Nombre d'accident par continent

DATA VISUALISATION – POWER BI

Microsoft Power BI est une solution de création de rapports complète qui permet de préparer, visualiser, distribuer et gérer des données avec des outils de développement et une plateforme en ligne.

Power BI convient aussi bien aux rapports simples utilisant une seule source de données qu'aux rapports nécessitant une modélisation de données complexe et des thèmes cohérents. Utilisez Power BI pour créer des rapports interactifs visuellement époustouflants qui servent de moteur d'analyse et de décision à des projets de groupe, à des départements ou à des organisations entières.

Power BI est un outil essentiel pour les analystes de données et leur organisation. Toutefois, la compréhension du fonctionnement de Power BI est un atout pour tous les professionnels de données qui souhaitent explorer et présenter des insights sur les données au sein des organisations.

DATA VISUALISATION – POWER BI

Pour créer des rapports avec Power BI, vous devez d'abord comprendre les outils nécessaires. Power BI se compose de trois éléments principaux :

- Power BI Desktop (application de bureau)
- Service Power BI (plateforme en ligne)
- Power BI Mobile (application mobile multiplateforme)

Power BI Desktop est l'outil de développement mis à la disposition des analystes de données et autres créateurs de rapports. Le service Power BI vous permet d'organiser, de gérer et de distribuer vos rapports et autres éléments Power BI. Power BI Desktop peut être téléchargé gratuitement via le magasin Windows ou directement en ligne.

DATA VISUALISATION – POWER BI

Service Power BI accessible à l'adresse **app.powerbi.com** avec un compte étudiant ou professionnel. Si votre organisation n'utilise pas encore Power BI, vous pouvez toujours explorer le service en obtenant une version d'essai gratuite ou en vous inscrivant à un compte développeur Microsoft 365 gratuit.

Power BI Mobile permet aux consommateurs de consulter des rapports dans un format optimisé pour les mobiles. Vous pouvez créer des vues de rapport optimisées dans Power BI Desktop.

DATA VISUALISATION – POWER BI

Power BI Desktop



Power BI service



Power BI Mobile



EXPLORER LE FLUX DE POWER BI

- La création de rapports avec Power BI suit un processus commun. Vous commencez par utiliser Power BI Desktop pour vous connecter aux données et créer le rapport. Ensuite, vous publiez le rapport sur le service Power BI et le distribuez aux consommateurs.


Le flux de Power BI est le suivant :

- Connectez-vous aux données avec Power BI Desktop.
- Transformez et modélisez les données avec Power BI Desktop.
- Créez des visualisations et des rapports avec Power BI Desktop.
- Publiez le rapport dans le service Power BI.
- Distribuez et gérez des rapports dans le service Power BI.

Le service Power BI vous permet également de créer des tableaux de bord de haut niveau qui permettent d'explorer les rapports, et des applications pour regrouper facilement des rapports connexes à l'intention des utilisateurs dans un format simple


EXPLORER LE FLUX DE POWER BI

- Les composants de Power BI sont les **modèles sémantiques** et les **visualisations**.
- Créez un modèle sémantique, puis utilisez des visuels pour créer un rapport. Explorons ces éléments plus en détail et leur relation avec le flux de Power BI.




EXPLORER LE FLUX DE POWER BI

- Les tableaux de bord constituent un excellent moyen de fournir des informations générales aux consommateurs. Comme pour un tableau de bord dans un véhicule, incluez les informations les plus importantes dans un tableau de bord
- Les consommateurs peuvent ensuite accéder au rapport pour obtenir plus de détails



Organiser les éléments avec des espaces de travail

- Les espaces de travail sont la base du service Power BI. Lors de la publication d'un rapport, vous devez choisir un espace de travail
- Par défaut, chaque utilisateur a accès à Mon espace de travail, ce qui est idéal uniquement à des fins de tests. Lorsque vous souhaitez partager du contenu avec d'autres personnes, créez et utilisez toujours un espace de travail partagé



CONTRÔLE DES CONNAISSANCES

1. Quel est le flux d'activité classique dans Power BI ? *

- ☐ Créer un état dans le service Power BI, le partager dans Power BI Mobile et interagir avec lui dans Power BI Desktop
- ☐ Créer un état dans Power BI Desktop, le partager dans le service Power BI et interagir avec lui dans le service et Power BI Mobile
- ☐ Créer un état dans Power BI Mobile, le partager dans Power BI Desktop et interagir avec lui dans le service Power BI

2. Laquelle des propositions suivantes désigne des blocs élémentaires de Power BI ? *

- ☐ Vignettes et visualisations
- ☐ Modèles sémantiques et visualisations
- ☐ Modèles sémantiques et états

3. Comment s'appelle une collection d'états et de tableaux de bord dans Power BI ? *

- ☐ Le canevas
- ☐ Actualisation planifiée
- ☐ Une application